

Министерство науки и высшего образования Российской Федерации Федеральное государственное бюджетное образовательное учреждение высшего образования

«Московский государственный технический университет имени Н.Э. Баумана (национальный исследовательский университет)» (МГТУ им. Н.Э. Баумана)

ФАКУЛЬТ	ГЕТ	Информа	рматика и системы управления (ИУ)				
КАФЕДРА	Λ	Система об	бработки информации и управления				
ДИСЦИПЛ	ПИНА	Me	етоды машинного обучения				
	ОТЧЕ	ЕТ ПО ЛАБОРА	ТОРНОЙ РАЕ	SOTE № 3			
		Обработка пр	оизнаков (часть 2	2)			
		название лабо	раторной работы				
Группа		ИУ5-24М					
Студент		13.04.2022		Молева А. А.			
	дата в	ыполнения работы	подпись	фамилия, и.о.			
Преподаватель				Гапанюк Ю. Е.			
			подпись	фамилия, и.о.			

Цель работы

Цель лабораторной работы: изучение продвинутых способов предварительной обработки данных для дальнейшего формирования моделей.

Задание

- 1. Выбрать один или несколько наборов данных (датасетов) для решения следующих задач. Каждая задача может быть решена на отдельном датасете, или несколько задач могут быть решены на одном датасете. Просьба не использовать датасет, на котором данная задача решалась в лекции.
- 2. Для выбранного датасета (датасетов) на основе материалов лекций решить следующие задачи:
 - І. масштабирование признаков (не менее чем тремя способами);
 - II. обработку выбросов для числовых признаков (по одному способу для удаления выбросов и для замены выбросов);
 - III. обработку по крайней мере одного нестандартного признака (который не является числовым или категориальным);
 - IV. отбор признаков:
 - один метод из группы методов фильтрации (filter methods);
 - один метод из группы методов обертывания (wrapper methods);
 - один метод из группы методов вложений (embedded methods).

Текст программы

```
import pandas as pd
df = pd.read csv('data.csv')
df.info()
df[df.author.isna()]
#Масштабирование признаков
#StandartScaler
df digits = df.select dtypes(include=[int, float], exclude=None)
df digits columns = df digits.columns
# Обучаем StandardScaler на всей выборке и масштабируем
from sklearn.preprocessing import StandardScaler
scaler = StandardScaler()
df scaled part = pd.DataFrame(scaler.fit transform(df digits), columns=df dig
its columns)
df scaled = pd.concat([df scaled part, df.select dtypes(include=None, exclude
=[int, float])], axis=1)
df scaled
#Mean Normalisation
class MeanNormalisation:
    def fit(self, df):
        self.means = df.mean(axis=0)
        maxs = df.max(axis=0)
        mins = df.min(axis=0)
        self.ranges = maxs - mins
    def transform(self, df):
        param df scaled = (df - self.means) / self.ranges
        return param df scaled
    def fit transform(self, df):
        self.fit(df)
        return self.transform(df)
sc21 = MeanNormalisation()
data_mean_scaled = sc21.fit_transform(df_digits)
data mean scaled.describe()
df mean scaled2 = pd.concat([data mean scaled, df.select dtypes(include=None,
exclude=[int, float])], axis=1)
df mean scaled2.head()
#MinMax
# Обучаем StandardScaler на всей выборке и масштабируем
from sklearn.preprocessing import MinMaxScaler
minMaxScaler = MinMaxScaler()
df min max scaled part = pd.DataFrame(minMaxScaler.fit transform(df digits),
columns=df digits columns)
```

```
df min max scaled = pd.concat([df min max scaled part, df.select dtypes(inclu
de=None, exclude=[int, float])], axis=1)
df min max scaled.head()
#Обработка выбросов для числовых признаков
#Удаление выбросов
import numpy as np
df without blowout = df[(df['views'] < np.quantile(df['views'], 0.95)) \</pre>
                          & (df['views'] > np.quantile(df['views'], 0.05))]
df without blowout.head()
df without blowout.shape
print(round(100 - 100 * df without blowout.shape[0] / df.shape[0], 2), '% был
о удалено данных')
#Замена выбросов
df chq = df.copy()
df chg['views'] = np.where(df chg['views'] > np.quantile(df chg['views'], 0.9
5), \
                                np.quantile(df chg['views'], 0.95), df chg['vi
ews'])
df chg['views'] = np.where(df chg['views'] < np.quantile(df chg['views'], 0.0</pre>
5), \
                                np.quantile(df chg['views'], 0.05), df chg['vi
ews'])
df chq.head()
df chg.shape
#Обработка нестандартных признаков
df['date'] = pd.to datetime(df['date'])
df.dtypes
#Отбор признаков
#Метод фильтрации
import seaborn as sns
sns.heatmap(df.corr(), annot=True, fmt='.3f')
# Формирование DataFrame с сильными корреляциями
def make corr df(df):
   cr = df.corr()
    cr = cr.abs().unstack()
    cr = cr.sort values(ascending=False)
    cr = cr[cr >= 0.3]
    cr = cr[cr < 1]
    cr = pd.DataFrame(cr).reset index()
    cr.columns = ['f1', 'f2', 'corr']
    return cr
# Обнаружение групп коррелирующих признаков
def corr groups(cr):
    grouped feature list = []
    correlated groups = []
```

```
for feature in cr['f1'].unique():
        if feature not in grouped feature list:
            # находим коррелирующие признаки
            correlated block = cr[cr['f1'] == feature]
            cur dups = list(correlated block['f2'].unique()) + [feature]
            grouped feature list = grouped feature list + cur dups
            correlated groups.append(cur dups)
    return correlated groups
# Группы коррелирующих признаков
corr groups(make corr df(df))
#Метод из группы методов вложений
df2 = pd.read spss('1ResearchProjectData.sav')
from sklearn.preprocessing import LabelEncoder
labelEnc = LabelEncoder()
col dict = {}
for col in df2.select dtypes(include=None, exclude=float):
    k = labelEnc.fit transform(df2[col])
    col dict[col] = k
df2 labeled = pd.concat([pd.DataFrame(col dict), df2.select dtypes(include=f1
oat)], axis=1)
df2 labeled
df2 labeled.info()
df2 labeled notna = df2 labeled.dropna(axis=0)
df2 labeled notna
from sklearn.linear model import LogisticRegression
from sklearn.svm import LinearSVC
# Используем L1-регуляризацию
e lr1 = LogisticRegression(C=1000, solver='liblinear', penalty='l1', max iter
=500, random state=1)
X, y = df2 labeled notna.drop('Score', axis=1), df2 labeled notna['Score']
e lr1.fit(X, y)
# Коэффициенты регрессии
# e lr1.coef
# Все 4 признака являются "хорошими"
sel e lr1 = SelectFromModel(e lr1)
sel e lr1.fit(X, y)
sel e lr1.get_support()
#Метод обертывания
import joblib
import sys
sys.modules['sklearn.externals.joblib'] = joblib
from mlxtend.feature selection import ExhaustiveFeatureSelector as EFS
from sklearn.neighbors import KNeighborsClassifier
knn = KNeighborsClassifier(n neighbors=3)
efs1 = EFS(knn,
```

Экранные формы

	title	author	date	views	likes	link
0	Climate action needs new frontline leadership	Ozawa Bineshi Albert	December 2021	404000	12000	https://ted.com/talks/ozawa_bineshi_albert_cli
1	The dark history of the overthrow of Hawaii	Sydney laukea	February 2022	214000	6400	https://ted.com/talks/sydney_iaukea_the_dark_h
2	How play can spark new ideas for your business	Martin Reeves	September 2021	412000	12000	$https://ted.com/talks/martin_reeves_how_play_c$
3 V	Why is China appointing judges to combat clima	James K. Thornton	October 2021	427000	12000	$https://ted.com/talks/james_k_thornton_why_is\$
4	Cement's carbon problem — and 2 ways to fix it	Mahendra Singhi	October 2021	2400	72	$https://ted.com/talks/mahendra_singhi_cement_s$
5435	The best stats you've ever seen	Hans Rosling	February 2006	15000000	458000	https://ted.com/talks/hans_rosling_the_best_st
5436	Do schools kill creativity?	Sir Ken Robinson	February 2006	72000000	2100000	https://ted.com/talks/sir_ken_robinson_do_scho
5437	Greening the ghetto	Majora Carter	February 2006	2900000	88000	https://ted.com/talks/majora_carter_greening_t
5438	Simplicity sells	David Pogue	February 2006	2000000	60000	https://ted.com/talks/david_pogue_simplicity_s
5439	Averting the climate crisis	Al Gore	February 2006	3600000	109000	https://ted.com/talks/al_gore_averting_the_cli

5440 rows × 6 columns

Рисунок 1 – Датасет 1

	views	likes	title	author	date	link
0	-0.464727	-0.470170	Climate action needs new frontline leadership	Ozawa Bineshi Albert	2021-12-01	https://ted.com/talks/ozawa_bineshi_albert_cli
1	-0.517997	-0.522197	The dark history of the overthrow of Hawaii	Sydney laukea	2022-02-01	https://ted.com/talks/sydney_iaukea_the_dark_h
2	-0.462485	-0.470170	How play can spark new ideas for your business	Martin Reeves	2021-09-01	https://ted.com/talks/martin_reeves_how_play_c
3	-0.458279	-0.470170	Why is China appointing judges to combat clima	James K. Thornton	2021-10-01	https://ted.com/talks/james_k_thornton_why_is
4	-0.577322	-0.580987	Cement's carbon problem — and 2 ways to fix it	Mahendra Singhi	2021-10-01	$https://ted.com/talks/mahendra_singhi_cement_s$
5435	3.627491	3.673392	The best stats you've ever seen	Hans Rosling	2006-02-01	https://ted.com/talks/hans_rosling_the_best_st
5436	19.608336	18.928387	Do schools kill creativity?	Sir Ken Robinson	2006-02-01	https://ted.com/talks/sir_ken_robinson_do_scho
5437	0.235065	0.235908	Greening the ghetto	Majora Carter	2006-02-01	https://ted.com/talks/majora_carter_greening_t
5438	-0.017264	-0.024226	Simplicity sells	David Pogue	2006-02-01	https://ted.com/talks/david_pogue_simplicity_s
5439	0.431321	0.431008	Averting the climate crisis	Al Gore	2006-02-01	https://ted.com/talks/al_gore_averting_the_cli
5440 rows x 6 columns						

Рисунок 2 – StandardScaler

	views	likes	title	author	date	link
(-0.023022	-0.024099	Climate action needs new frontline leadership	Ozawa Bineshi Albert	2021-12-01	https://ted.com/talks/ozawa_bineshi_albert_cli
1	-0.025661	-0.026766	The dark history of the overthrow of Hawaii	Sydney laukea	2022-02-01	https://ted.com/talks/sydney_iaukea_the_dark_h
2	-0.022911	-0.024099	How play can spark new ideas for your business	Martin Reeves	2021-09-01	https://ted.com/talks/martin_reeves_how_play_c
3	-0.022703	-0.024099	Why is China appointing judges to combat clima	James K. Thornton	2021-10-01	https://ted.com/talks/james_k_thornton_why_is
4	-0.028600	-0.029779	Cement's carbon problem — and 2 ways to fix it	Mahendra Singhi	2021-10-01	https://ted.com/talks/mahendra_singhi_cement_s

	views	likes	title	author	date	link
(0.005604	0.005707	Climate action needs new frontline leadership	Ozawa Bineshi Albert	2021-12-01	https://ted.com/talks/ozawa_bineshi_albert_cli
	0.002965	0.003040	The dark history of the overthrow of Hawaii	Sydney laukea	2022-02-01	https://ted.com/talks/sydney_iaukea_the_dark_h
1	0.005715	0.005707	How play can spark new ideas for your business	Martin Reeves	2021-09-01	https://ted.com/talks/martin_reeves_how_play_c
;	0.005923	0.005707	Why is China appointing judges to combat clima	James K. Thornton	2021-10-01	https://ted.com/talks/james_k_thornton_why_is
4	0.000026	0.000027	Cement's carbon problem — and 2 ways to fix it	Mahendra Singhi	2021-10-01	$https://ted.com/talks/mahendra_singhi_cement_s$

Рисунок 4 – МіпМах-масштабирование



Рисунок 5 – Удаление выбросов

```
[ ] df_chg = df.copy()
     df_chg['views'] = np.where(df_chg['views'] > np.quantile(df_chg['views'], 0.95), \
                                       np.quantile(df_chg['views'], 0.95), df_chg['views'])
     df_chg['views'] = np.where(df_chg['views'] < np.quantile(df_chg['views'], 0.05), \</pre>
                                       np.quantile(df_chg['views'], 0.05), df_chg['views'])
    df_chg.head()
8
                                                                    author
                                                                                           views likes
             Climate action needs new frontline leadership Ozawa Bineshi Albert 2021-12-01 404000.0 12000
                                                                                                             https://ted.com/talks/ozawa_bineshi_albert_cli...
               The dark history of the overthrow of Hawaii
                                                             Sydney laukea 2022-02-01 214000.0
                                                                                                    6400
                                                                                                           https://ted.com/talks/sydney iaukea the dark h...
          How play can spark new ideas for your business
                                                             Martin Reeves 2021-09-01 412000.0 12000
                                                                                                            https://ted.com/talks/martin_reeves_how_play_c...
         Why is China appointing judges to combat clima...
                                                          James K. Thornton 2021-10-01 427000.0 12000
                                                                                                            https://ted.com/talks/james_k_thornton_why_is_.
           Cement's carbon problem - and 2 ways to fix it
                                                           Mahendra Singhi 2021-10-01
                                                                                          18000.0
                                                                                                          https://ted.com/talks/mahendra singhi cement s.
[ ] df_chg.shape
     (5440, 6)
```

Рисунок 6 – Замена выбросов

```
df.info()
    <class 'pandas.core.frame.DataFrame'>
    RangeIndex: 5440 entries, 0 to 5439
    Data columns (total 7 columns):
         Column
                    Non-Null Count Dtype
        title
                    5440 non-null
                                    object
     1
       author
                    5439 non-null object
                                   datetime64[ns]
     2
         date
                    5440 non-null
     3 views
                    5440 non-null int64
     4 likes
                    5440 non-null
                                    int64
     5
         link
                    5440 non-null object
     6 split date 5440 non-null
                                    datetime64[ns]
    dtypes: datetime64[ns](2), int64(2), object(3)
    memory usage: 297.6+ KB
[ ] df['date'] = pd.to_datetime(df['date'])
[ ] df.dtypes
    title
                         object
    author
                         object
    date
                  datetime64[ns]
    views
                          int64
    likes
                          int64
    link
                         object
    split_date
                  datetime64[ns]
    dtype: object
```

Рисунок 7 – Обработка нестандартного признака

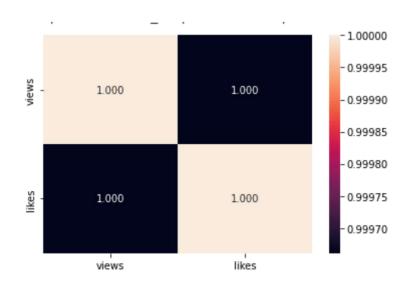


Рисунок 8 – Метод фильтрации (Корреляция признаков)

```
from sklearn.feature_selection import SelectFromModel

# Все 6 признаков являются "хорошими"

sel_e_lr1 = SelectFromModel(e_lr1)

sel_e_lr1.fit(X, y)

sel_e_lr1.get_support()
```

/usr/local/lib/python3.7/dist-packages/sklearn/svm/_base.py:1208: ConvergenceWarning: Liblinear failed to converge, increase the number of iterations. ConvergenceWarning, array([True, True, True, True, True, True, True])

Рисунок 9 - Метод из группы методов вложений

Userwarming, Features: 50/50Best accuracy score: -18.08 Best subset (indices): (0, 1, 2)

Рисунок 10 – Метод обертывания (wrapper methods)

Выводы

В результате проделанной работы были решены следующие задачи: масштабирование признаков; обработка выбросов; обработка нестандартного признака; отбор признаков.